

# Code Smells (Crawler) - A4

## Resumo

Categoria (Refactoring Guru)	Smell	Refatoracao aplicada
Bloaters - Long Parameter List	Pipeline precisava passar 5 argumentos dispersos para obter o curriculo	Introduce Parameter Object com <code>CurriculumParams</code> e leitura via <code>_read_html</code>
Couplers - Global Data	Funcoes HTTP dependiam da constante global <code>BASE</code>	Dependency Injection utilizando <code>CrawlerSettings</code> e helper <code>_url()</code>
Dispensables - Duplicate Code	Cada chamada salvava HTML montando nome de arquivo manualmente	Extract Method em <code>utils.io_raw.save_raw</code> com hash/time para nome unico
Change Preventers - Divergent Change	Ajustar estrategia exigia tocar CLI, pipeline e funcoes HTTP ao mesmo tempo	Introduce Strategy ( <code>AjaxStrategy</code> / <code>FullPageStrategy</code> ) e seletor <code>fetch_with_strategy</code>

## Bloaters - Long Parameter List

- **Onde ocorria:** `crawler/src/crawler_app/collectors/enumerate_pipeline.py:130` (antes do refactor).
- **Sintoma:** A coleta de cada modalidade repassava `curso_id`, `catalogo_id`, `modalidade_id`, `periodo_id`, `cp` separadamente para `fetch_arvore_with_params`, poluindo a assinatura e dificultando evolucao.
- **Risco:** Inclusao de um novo filtro ou estrategia demandava adicionar argumentos em varias funcoes, elevando chance de inconsistencias e bugs silenciosos.
- **Refactoring aplicado:** *Introduce Parameter Object* (`CurriculumParams`) encapsulando o conjunto de parametros e reaproveitado na Strategy e nos parsers.
- **Evidencia "Antes/Depois":**

```
-         html_arvore = fetch_arvore_with_params(  
-             session,  
-             curso_id=curso_id,  
-             catalogo_id=CATALOGO_TARGET,  
-             modalidade_id=mid,  
-             periodo_id=PERIODO_TARGET,  
-             cp=CP_TARGET,  
-             raw_dir=arvore_dir,  
-         )  
+         params = CurriculumParams(  
+             curso_id=curso_id,  
+             catalogo_id=catalogo_int,
```

```

+         modalidade_id=modalidade_id,
+         periodo_id=str(PERODO_TARGET),
+         cp=str(CP_TARGET),
+     )
+     raw_path = fetch_with_strategy(session, settings, params, arvore_dir)
+     html_arvore = _read_html(raw_path)

```

- **Resultados:** Parametros passaram a viajar como objeto imutavel, simplificando testes e reduzindo a necessidade de sincronizar funcoes quando o escopo muda.

## Couplers - Global Data

- **Onde ocorria:** `crawler/src/crawler_app/collectors/arvore_http.py:1-70` (versao anterior usava `BASE` global).
- **Sintoma:** As funcoes HTTP dependiam da constante `BASE` definida em `collectors/config.py`, acoplando endpoints ao estado global e dificultando apontar para ambientes alternativos.
- **Risco:** Alterar `base_url` exigia editar modulos diferentes ou confiar em mocks complexos, aumentando risco de configuracao incorreta entre dev e prod.
- **Refactoring aplicado:** *Dependency Injection* com `CrawlerSettings` (Refactoring Guru -> Couplers/Global Data) e helper `_url()` para montar caminhos a partir da configuracao.
- **Evidencia "Antes/Depois":**

```

-from .config import BASE
-
-def fetch_arvore_page(session: requests.Session, *, raw_dir: str, label: str,
curso_id: Optional[str] = None) -> str:
-     params = {"curso": curso_id} if curso_id else {}
-     resp = session.get(f"{BASE}/arvore/", params=params, timeout=30)
+from ..config.settings import CrawlerSettings
+
+def fetch_arvore_page(
+     session: requests.Session,
+     settings: CrawlerSettings,
+     *,
+     raw_dir: str,
+     label: str,
+     curso_id: Optional[int] = None,
+) -> str:
+     params = {"curso": curso_id} if curso_id is not None else {}
+     resp = session.get(
+         _url(settings, "/arvore/"),
+         params=params,
+         timeout=settings.timeout_s,
+     )

```

- **Resultados:** Agora basta ajustar `.env` ou passar `--base-url` na CLI para redirecionar a coleta; testes podem injetar URLs fake e timeouts customizados.

## Dispensables - Duplicate Code

- **Onde ocorria:** `crawler/src/crawler_app/utils/io_raw.py:8-18` (assinatura antiga de `save_raw`).
- **Sintoma:** Cada chamada precisava montar nomes unicos e garantir `ensure_dir` manualmente, gerando repeticao de logica e risco de sobrescrita de arquivos.
- **Risco:** Em execucoes seguidas, HTMLs eram sobrescritos porque os nomes eram previsiveis; tambem aumentava o ruido ao adicionar novos coletores.
- **Refactoring aplicado:** *Extract Method* com responsabilidade de naming em `save_raw`, usando hash do `name_hint` mais timestamp.
- **Evidencia "Antes/Depois":**

```
-def save_raw(base_dir: str, filename: str, content: str) -> str:
-    ensure_dir(base_dir)
-    fullpath = os.path.join(base_dir, filename)
-    with open(fullpath, "w", encoding="utf-8") as f:
-        f.write(content if content is not None else "")
-    return fullpath
+def save_raw(html: str, raw_dir: str, name_hint: str) -> str:
+    ensure_dir(raw_dir)
+    key = hashlib.md5(name_hint.encode("utf-8")).hexdigest()
+    filename = f"{int(time.time())}_{key}.html"
+    path = os.path.join(raw_dir, filename)
+    with open(path, "w", encoding="utf-8") as f:
+        f.write(html if html is not None else "")
+    return path
```

- **Resultados:** Saidas RAW tornaram-se idempotentes, com colisoes improvaveis e sem duplicar logica de criacao de nome em cada Strategy ou helper.

## Change Preventers - Divergent Change

- **Onde ocorria:** `crawler/src/crawler_app/collectors/enumerate_pipeline.py` executava fluxo HTTP direto sem abstrair estrategia.
- **Sintoma:** Alterar a forma de busca (AJAX x pagina cheia) exigia modificar CLI, pipeline e helpers, causando "shotgun surgery" sempre que o GDE mudava comportamento.
- **Risco:** Dificuldade de aplicar hotfix rapido em campo; fallback manual era esquecido e a coleta falhava por completo diante de erros do endpoint AJAX.
- **Refactoring aplicado:** *Introduce Strategy* com `fetch_with_strategy` centralizando a decisao e fallback automatico.
- **Evidencia "Antes/Depois":**

```
-from .arvore_http import (
-    polite_sleep,
-    fetch_arvore_page,
-    fetch_modalidades_fragment,
-    fetch_arvore_with_params,
-)
+from .arvore_http import fetch_arvore_page, fetch_modalidades_fragment,
+    polite_sleep
+from .strategies import AjaxStrategy, FullPageStrategy
```

```

...
-         polite_sleep()
-         try:
-             html_arvore = fetch_arvore_with_params(
-                 session,
-                 curso_id=curso_id,
-                 catalogo_id=CATALOGO_TARGET,
-                 modalidade_id=mid,
-                 periodo_id=PERIODO_TARGET,
-                 cp=CP_TARGET,
-                 raw_dir=arvore_dir,
-             )
+         polite_sleep(settings)
+         params = CurriculumParams(
+             curso_id=curso_id,
+             catalogo_id=catalogo_int,
+             modalidade_id=modalidade_id,
+             periodo_id=str(PERIODO_TARGET),
+             cp=str(CP_TARGET),
+         )
+
+         try:
+             raw_path = fetch_with_strategy(session, settings, params,
arvore_dir)
+             html_arvore = _read_html(raw_path)

```

- **Resultados:** Qualquer nova estratégia (ex.: headless browser) pode ser adicionada com classe dedicada, sem alterar CLI; fallback garante continuidade mesmo com falhas temporárias.

## Mapa de rastreabilidade

- Long Parameter List -> commit [af938da8](#) ("AV4 - Code Smells") -> arquivos [collectors/enumerate\\_pipeline.py](#), [types.py](#).
- Global Data -> commit [af938da8](#) -> arquivo [collectors/arvore\\_http.py](#).
- Duplicate Code -> commit [af938da8](#) -> arquivo [utils/io\\_raw.py](#).
- Divergent Change -> commit [af938da8](#) -> arquivos [collectors/enumerate\\_pipeline.py](#), [collectors/strategies/\\*.py](#), [cli.py](#).

## Como validar

- Executar `python -m src.crawler_app.cli collect --strategy auto` e verificar logs de fallback.
- Rodar `python -m src.crawler_app.cli curriculum --course-id 34 --year 2022 --strategy full` e checar HTML salvo em `crawler/data/raw`.
- Inspecionar `crawler/data/json` para confirmar deduplicação de disciplinas.
- Conferir logs para `AjaxStrategy` `falhou` quando `CRAWLER_STRATEGY=auto` aciona o fallback.

## Referencias

- Refactoring Guru - Code Smells: <https://refactoring.guru/refactoring/smells>
- Refactoring Guru - Bloaters / Long Parameter List

- Refactoring Guru - Couplers / Global Data
- Refactoring Guru - Dispensables / Duplicate Code
- Refactoring Guru - Change Preventers / Divergent Change